



COMENIUS UNIVERSITY IN BRATISLAVA
FACULTY OF MATHEMATICS PHYSICS AND INFORMATICS



**MACHINE LEARNING ALGORITHM FOR
TRACKLET BUILDING IN ASTRONOMICAL
IMAGE PROCESSING**

Master thesis

COMENIUS UNIVERSITY IN BRATISLAVA
FACULTY OF MATHEMATICS PHYSICS AND INFORMATICS



MACHINE LEARNING ALGORITHM FOR TRACKLET BUILDING IN ASTRONOMICAL IMAGE PROCESSING

Master thesis

Study program: Applied informatics
Branch of study: Applied informatics
Department: Department of Applied Informatics
Supervisor: prof. RNDr. Roman Ďurikovič, PhD.
Consultant: Mgr. Matej Zigo, PhD.



Univerzita Komenského v Bratislave
Fakulta matematiky, fyziky a informatiky

ZADANIE ZÁVEREČNEJ PRÁCE

Meno a priezvisko študenta: Bc. Lucia Lahučká
Študijný program: aplikovaná informatika (Jednoodborové štúdium, magisterský II. st., denná forma)
Študijný odbor: informatika
Typ záverečnej práce: diplomová
Jazyk záverečnej práce: slovenský
Sekundárny jazyk: anglický

Názov: Algoritmus strojového učenia pre tvorbu trackletov v spracovaní astronomických obrazov
Machine Learning algorithm for tracklet building in astronomical image processing

Anotácia: Nominálne spracovanie astronomických údajov na účely monitorovania vesmírnej situácie (SSA) alebo planetárnej obrany zahŕňa štandardný spracovateľský obrazový pipeline. Takéto pipeline zahŕňa extrakciu pozadia zo surových snímok (odhad nominálneho pozadia a jeho odčítanie zo surových snímok), segmentáciu (meranie súradníc xy objektov na snímke), astrometrickú redukciu (konverziu medzi xy a nebeskými súradnicami), fotometrickú redukciu (odhad fotometrickej nulovej hodnoty a maskovanie hviezd), tvorbu trackletov (identifikácia pohybujúcich sa objektov na snímke), identifikáciu objektov (koreláciu uhlovej polohy pohybujúceho sa objektu s katalogizovanými hodnotami) a konverziu dát (generovanie štandardných dátových formátov). Všetky tieto kroky sú potrebné na analytické získanie uhlovej polohy pohybujúceho sa objektu zo surových astronomických snímok vo formáte FITS. Avšak analytický prístup je značne obmedzený nesprávnou koreláciou objektov s hviezdami alebo inými artefaktmi snímky, čo vedie k generovaniu nepresných výsledných údajov s vysokým šumom. Ľudské oko dokáže priamo rozpoznať objekt vďaka jeho relatívnemu pohybu voči hviezdám v pozadí. To naznačuje, že inteligentne vybraný a trénovaný algoritmus strojového učenia môže nahradiť modul na tvorbu trackletov a zvýšiť efektívnosť a presnosť vytvoreného trackletu (tracklet = časová séria uhlových pozícií). Astros Solutions s.r.o. má k dispozícii rozsiahlu databázu trackletov spracovaných analytickým alebo manuálnym prístupom operátora. Súčasná databáza obsahuje viac ako 2000 trackletov z rôznych ďalekohľadov. Hlavná myšlienka nie je nahradiť celý pipeline spracovania obrazu, ale len algoritmus tvorby trackletu strojovým učením, t.j. načítať výstup z fotometrickej redukcie vo forme údajov vo formáte JSON a využiť predpoklad relatívneho pohybu cieľa voči hviezdám v pozadí na jeho identifikáciu v súbore údajov. Naša sieť malých ďalekohľadov je schopná získavať nové údaje, ak bude potrebná širšia štatistika na trénovanie algoritmu strojového učenia. Cieľom práce je najprv preskúmať analytické algoritmy na tvorbu trackletov a identifikovať možné možnosti strojového učenia pre túto úlohu. Následne by mal byť definovaný trénovací dataset, implementovaný a natrénovaný algoritmus strojového učenia na testovacím datasete z našich senzorov.



Univerzita Komenského v Bratislave
Fakulta matematiky, fyziky a informatiky

Validácia algoritmu strojového učenia môže byť vykonaná na nových pozorovaniach, ktoré vznikajú viac-menej každú noc.

Navyše, strojové učenie je široko používaný prístup na identifikáciu pohybujúcich sa častíc na snímkach nielen v astronomickom prostredí, ale aj v mikroskopii, napríklad pri identifikácii a sledovaní pohybujúcich sa buniek medzi ostatnými bunkami počas času.

Cieľ: Vyvinúť a natrénovať algoritmus strojového učenia na identifikáciu pohybujúceho sa objektu na segmentovaných a astrometrizovaných astronomických snímkach vďaka jeho relatívnemu pohybu voči hviezdám v pozadí, porovnateľne s ľudským okom. Hlavným cieľom je vyvinúť algoritmus strojového učenia, ktorý nahradí analytický prístup, bude efektívnejší z hľadiska nesprávnej korelácie a bude vyžadovať menej vstupných parametrov.

Literatúra: KRAJČOVIČ, Stanislav; ĎURIKOVIČ, Roman; ŠILHA, Jiří. Selected modules from the Slovak Image Processing Pipeline for space debris and near earth objects observations and research. In: 2019 23rd International Conference Information Visualisation (IV). IEEE, 2019. p. 112-117.
<https://ieeexplore.ieee.org/stamp/stamp.jsp?tp=&arnumber=8812053>

SCHILDKNECHT, T.; HUGENTOBLE, U.; VERDUN, A. Algorithms for ground based optical detection of space debris. Advances in Space Research, 1995, 16.11: 47-50.
<https://www.sciencedirect.com/science/article/pii/027311779598752A>

SMAL, Ihor, et al. Particle filtering for multiple object tracking in dynamic fluorescence microscopy images: Application to microtubule growth analysis. IEEE transactions on medical imaging, 2008, 27.6: 789-804.

FRASER, Wesley C. Detecting Moving Objects With Machine Learning. arXiv preprint arXiv:2405.06148, 2024.

Kľúčové

slová: tracklet, strojové učenie

Vedúci: prof. RNDr. Roman Ďurikovič, PhD.

Konzultant: Mgr. Jiří Šilha, PhD.

Konzultant: Mgr. Matej Zigo, PhD.

Katedra: FMFI.KAI - Katedra aplikovanej informatiky

Vedúci katedry: doc. RNDr. Tatiana Jajcayová, PhD.

Spôsob sprístupnenia elektronickej verzie práce:

bez obmedzenia

Dátum zadania: 22.10.2024

Dátum schválenia: 22.10.2024

prof. RNDr. Roman Ďurikovič, PhD.
garant študijného programu

I hereby declare on my honour that the whole work, including all its appendices and figures, I have prepared independently, using the literature listed in the attached list and artificial intelligence tools, under the careful supervision of my thesis advisor. I declare that the tools artificial intelligence tools have been used by me in accordance with the relevant legislation, academic rights and freedoms, and ethical and moral principles, while respecting academic integrity and that their use is appropriately indicated in the thesis.

Bratislava, 2024

.....
Bc. Lucia Lahučká

Acknowledgement

First, I would like to express my gratitude to Mgr. Jiří Šilha, PhD. and Mgr. Matej Zigo, PhD. for their guidance during the whole thesis and invaluable expertise in astronomy that made this thesis possible. I'd also like to thank my supervisor prof. RNDr. Roman Ďurikovič, PhD. for his insightful feedback and organization of YACGS seminars. And lastly, I'd like to express my deepest thanks to my family for supporting me during my academic years.

Abstract

This thesis explores the application of machine learning to the problem of tracklet generation in astronomical image processing, a critical task in domains such as Space Situational Awareness (SSA) and planetary defense. The standard processing pipeline—from raw image calibration to object identification—often relies on deterministic, rule-based methods that are prone to errors when correlating object positions, particularly in dense or noisy star fields. This work proposes the replacement of the analytical tracklet-building module with a machine learning-based solution capable of identifying moving objects based on their relative motion against static background stars. Leveraging a labeled dataset of over 2000 tracklets derived from both manual and automated methods, the goal is to train and validate a model that can perform tracklet generation with higher accuracy and lower false correlation rates. The model will operate on JSON-formatted outputs of photometric reductions, enabling easy integration into existing processing pipelines. The proposed solution is expected to outperform traditional methods in precision, adaptability, and robustness, while reducing dependence on manual intervention and heuristic parameters.

Keywords: space debris, machine learning, tracklet building

Abstrakt

Táto diplomová práca sa zaoberá využitím algoritmov strojového učenia na tvorbu trackletov v spracovaní astronomických snímok, čo je kľúčová úloha v oblastiach ako monitorovanie vesmírnej situácie (SSA) a planetárna obrana. Štandardné spracovanie snímok, od kalibrácie až po identifikáciu objektov, často využíva deterministické analytické metódy, ktoré však môžu zlyhať pri korelácii objektov, najmä v husto posiatych alebo zašumených hviezdnych poliach. Navrhované riešenie spočíva v nahradení analytického modulu na tvorbu trackletov algoritmom strojového učenia, ktorý dokáže identifikovať pohybujúce sa objekty na základe ich relatívneho pohybu voči statickému hviezdному pozadiu. Model bude trénovaný na datasetoch obsahujúcich viac ako 2000 trackletov, získaných manuálne alebo analytickými metódami, a bude pracovať s výstupmi fotometrickej redukcie vo formáte JSON. Cieľom je dosiahnuť vyššiu presnosť, zníženie falošných korelácií a menšiu závislosť od vstupných parametrov v porovnaní s tradičnými prístupmi.

Kľúčové slová: vesmírny odpad, strojové učenie, budovanie trackletov

Contents

1	Introduction	2
1.1	Space debris	2
1.2	Deep learning	2
2	Astronomical data	3
3	Proposed method	4
4	Software design	5
5	Implementation	6
6	Data generation	7
7	Research	8
8	Results	9

List of Figures

List of Tables

Terminology

Terms

- **Star field tracking (sidereal)**
Ground-based tracking mode in which, telescope is moving in the same direction and speed as the apparent motion of stars.
- **Object tracking**
Tracking mode, where the focus is aimed at the moving object of interest and the telescope is moving in the same way.
- **Survey**
Observation of a region of the sky when no specific target is defined.
- **Star catalog**
A list of stars with its positions and magnitude.

Abbreviations

- **CNN** - Convolutional Neural Network.
- **ML** - Machine Learning.
- **PCA** - Principal Component Analysis.
- **ANN** - Artificial Neural Network.
- **NN** - Neural Network.
- **AGO** - Astronomical and Geophysical Observatory in Modra.
- **AGO70** - The Newtonian telescope at AGO, with 70 cm parabolic mirror.
- **FMPI** - Faculty of Mathematics, Physics and Informatics.
- **RADEC** - Right Ascension and Declination.
- **SVM** - Support-Vector Machine.

Motivation

The motivation behind this thesis lies in the limitations of current analytical methods used for identifying and tracking moving celestial objects in astronomical imagery. These methods often struggle in complex observational environments, where the presence of dense star fields, noise, and imaging artifacts can lead to incorrect object associations. Such errors reduce the reliability of systems designed for monitoring near-Earth objects or artificial satellites, where precise tracking is crucial for safety and research.

Unlike traditional algorithms, human observers excel at recognizing relative motion, intuitively distinguishing moving objects from static stars. This natural ability suggests that a machine learning approach—if properly trained—could emulate or even surpass human performance in this specific task. Moreover, Astros Solutions’ access to a large, diverse database of tracklets, combined with a functioning network of small telescopes, offers a unique opportunity to develop a statistically rich and representative training set.

The broader significance of this work extends beyond astronomy. The problem of motion-based object detection occurs in many scientific domains, including microscopy and medical imaging. By demonstrating the effectiveness of machine learning in astronomical tracklet building, this thesis contributes to a growing body of research that leverages data-driven techniques for dynamic pattern recognition across disciplines.

Chapter 1

Introduction

1.1 Space debris

1.2 Deep learning

Chapter 2

Astronomical data

Chapter 3

Proposed method

Chapter 4

Software design

Chapter 5

Implementation

Chapter 6

Data generation

Chapter 7

Research

Chapter 8

Results

Conclusion

In our thesis, we have first researched the relevant literature and introduced the topic of space debris, where we explained the theory, its origin and the current population in space. We also reviewed the current state of the space object recognition methods. In Chapter 2 we described the format and appearance of astronomical data obtained from space debris observations. We went into heavy detail about what features are present in the images as well as what noises and defects affect them. The gained knowledge proved useful when designing the generator of synthetic images - starGen. Based on the reviewed existing solutions to space object recognition, we proposed the architecture of the convolutional neural network defined in Chapter 4. We also described the various parameters of the network that need to be adjusted as well as some techniques to improve the generalization of our model. The implementation and the project structure of the generator and the network are explained in Chapter 5. Next, we described how we generated synthetic images for the training purposes of our network. We illustrated the appearance of each object, described the algorithm used to simulate the desired profile and established the object's parameters.

In Chapter 7 we have gone through an extensive process of tuning the network parameters and testing various regularization techniques. We have trained over 200 models on synthetic data and selected the one most suitable for the task. The model achieved 73 % accuracy on the testing dataset comprised of real images. We also deployed two approaches to fine-tune our model with real images and provided the results in Chapter 8. We have shown that incorporating real images in the training process has significantly improved the performance of our model which achieved an accuracy of 89 %. At last, our model is compared to the state-of-the-art ResNet-18 network, which achieved slightly worse results when training with just synthetic data but outperformed our model when adding the real images.

In future work, our research can be used to further improve the network by extending the scope of recognized objects. Our network can also be deployed as a subnetwork in a region-based convolutional neural network that includes the object localization step. Apart from the network, the implemented generator may be helpful for future works that require a large amount of astronomical data.

Bibliography

- [1] Wesley C Fraser. Detecting moving objects with machine learning. In *Machine Learning for Small Bodies in the Solar System*, pages 229–271. Elsevier, 2025.
- [2] Stanislav Krajčovič, Roman Ďurikovič, and Jiří Šilha. Selected modules from the slovak image processing pipeline for space debris and near earth objects observations and research. In *2019 23rd International Conference Information Visualisation (IV)*, pages 112–117. IEEE, 2019.
- [3] Daniel Kyselica. Advanced algorithms for segmentation of space debris astronomical images. Master’s thesis, Comenius University, FMPI, 2021.
- [4] T Schildknecht, U Hugentobler, and A Verdun. Algorithms for ground based optical detection of space debris. *Advances in Space Research*, 16(11):47–50, 1995.
- [5] Ihor Smal, Katharina Draegestein, Niels Galjart, Wiro Niessen, and Erik Meijering. Particle filtering for multiple object tracking in dynamic fluorescence microscopy images: Application to microtubule growth analysis. *IEEE transactions on medical imaging*, 27(6):789–804, 2008.